#### **Examen Final**

Nombre: LEONEL ALVARO CHAMACA LIMA

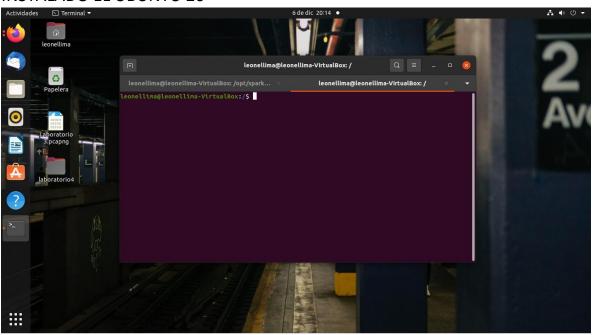
C.I: 6853618 LP

1. En una máquina virtual realice la configuración de apache spark, puede guiarse en cualquier tutorial o el proporcionado por el docente.

url: <a href="https://computingforgeeks.com/how-to-install-apache-spark-on-ubuntu-debian/">https://computingforgeeks.com/how-to-install-apache-spark-on-ubuntu-debian/</a>

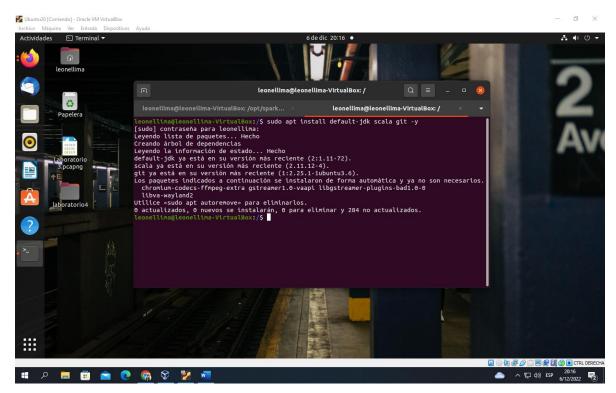
Con el shell podra ejecutar scala por defecto Instale Python para spark

1. INICIAR LA MAQUINA VIRTUAL INSTALADO EL UBUNTU 20



# 2. ENTRAR A LA CONSOLA EN INSERTAR LA SIGUIENTE LINEA DE CODIGO

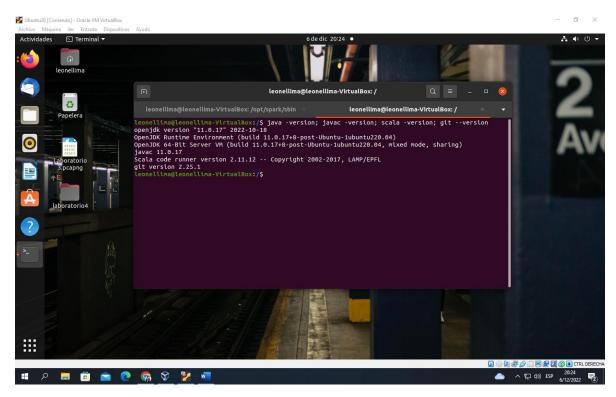
# sudo apt install default-jdk scala git -y



Antes de descargar y configurar Spark, necesitamos instalar dependencias. Estos pasos incluyen la instalación de la siguiente paquetería. JDK, Scala Git, Ya que lo tengo instalado, me sale ese mensaje, al contrario si no lo tendria instalado, empezaria la descarga.

#### 3. Verificamos la versión que tenemos con el comando

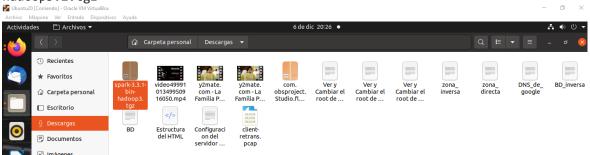
java -version; javac -version; scala -version; git -version



Verificamos la versión para continuar.

#### 4. DESCARGAMOS SPARK POR EL SIGUIENTE COMANDO

wget https://dlcdn.apache.org/spark/spark-3.2.1/spark-3.2.1-binhadoop3.2.tgz



Lo que hará será descargar la carpeta spark y la versión deseada

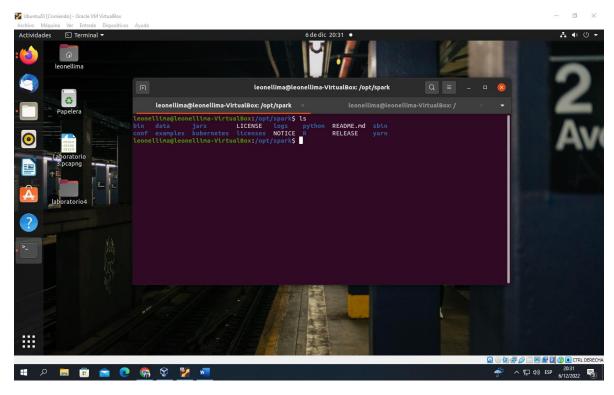
#### 5. Descomprimimos con el comando

tar xvf spark-\*

Recordemos que una vez descomprimido tenemos que buscar la carpeta SPARK para trasladarla al OTC

# Con el siguiente comando

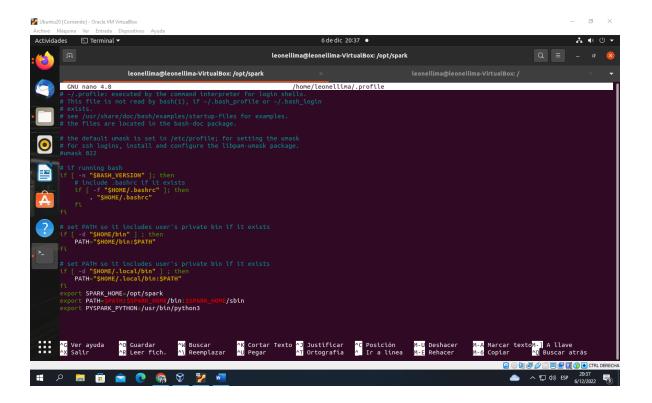
# sudo mv spark-3.2.1-bin-hadoop3.2 /opt/spark



Ya dentro podremos observar todas las carpetas dentro del spark

6. CREAMOS UN ENTORNO PARA SPARK

nano ~/.profile



### Copiamos las siguientes líneas de código

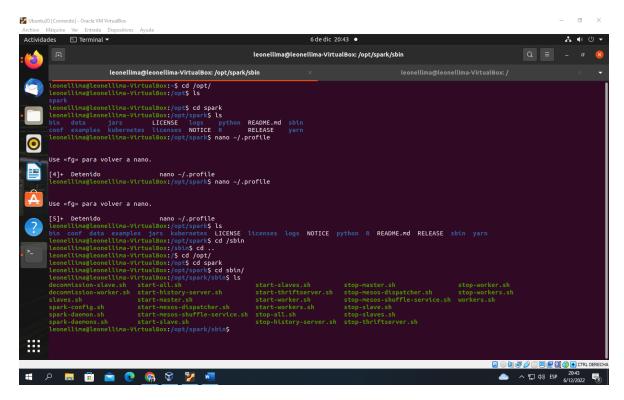
echo "export SPARK\_HOME=/opt/spark" >> ~/.profile echo "export PATH=\$PATH:\$SPARK\_HOME/bin:\$SPARK\_HOME/sbin" >> ~/.profile echo "export PYSPARK\_PYTHON=/usr/bin/python3" >> ~/.profile

### Despues introducimos la siguiente código

source ~/.profile

para que se guarde.

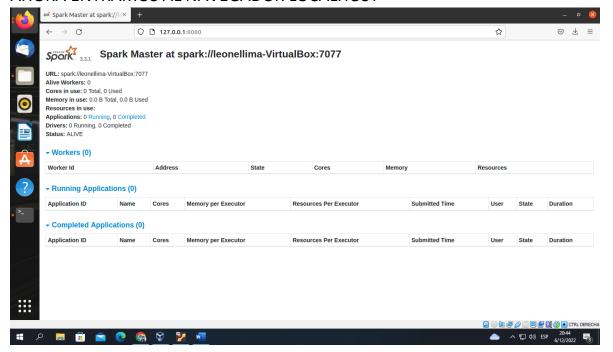
7. Ahora iniciamos la vertificación de la instalación de SPARK



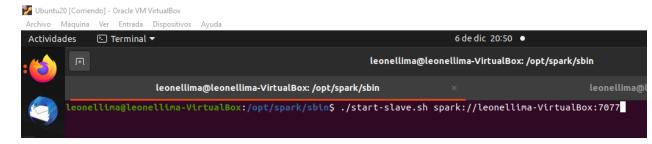
Para verificar si ya esta instalado correctamente activaremos el script que se encuentra en la carperta SBIN, ingresamos e activamos el script

"start-master.sh"

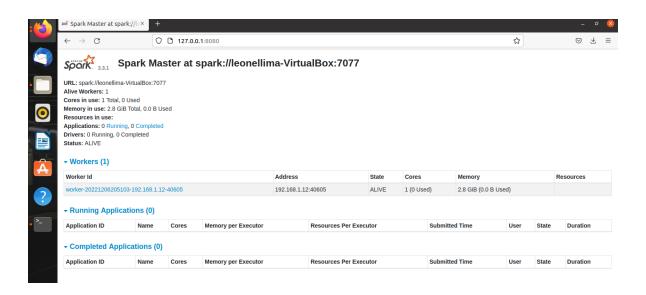
#### 8. AHORA ENTRAMOS AL NAVEGADOR LOCALHOST



#### 9. ACTIVAMOS EL ESCLAVO

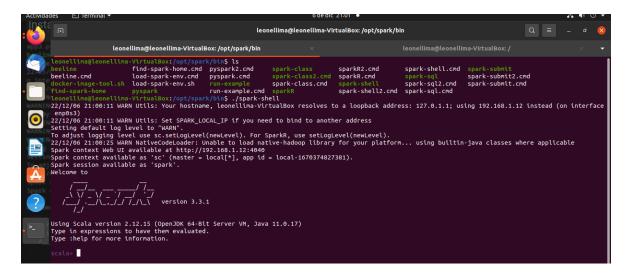


#### COPIAMOS LA URL QUE NOS MUESTRA LA VENTANA DEL SPARK

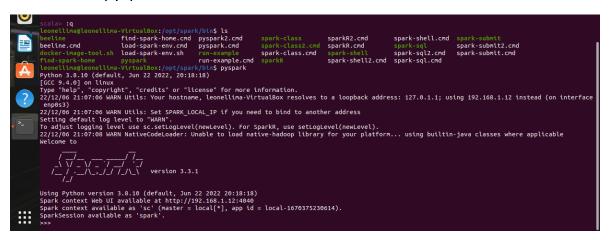


Ya tenemos el esclavo funcionando Ahora ya vemos que funciona iniciamos con la SPARK SHELL

10. Entramos a BIN para activar el script Shell



#### Y ahora con pyspark



2. Realice el siguiente código, documente su funcionamiento en apache spark

# Sesiones

Paso 1: Debemos importar las siguientes librerias

import org.apache.spark.sql.SparkSession

#### Paso 2: Iniciaremos colocando la primera linea de codigo

```
val spark: SparkSession = SparkSession.builder()
   .master("local[*]")
   .appName("simple-app")
   .getOrCreate()
```

```
scala> val spark = SparkSession
spark: org.apache.spark.sql.SparkSession.type = org.apache.spark.sql.SparkSession$@77d5@cde

scala> .builder()
res0: spark.Builder = org.apache.spark.sql.SparkSession$Builder@399ebdee

scala> .appName("Spark SQL basic example")
res1: spark.Builder = org.apache.spark.sql.SparkSession$Builder@399ebdee

scala> .config("spark.some.config.option", "some-value")
res2: spark.Builder = org.apache.spark.sql.SparkSession$Builder@399ebdee

scala> .getOrCreate()
22/12/11 18:46:18 WARN SparkSession: Using an existing Spark session; only runtime SQL configurations will take effect.
res3: org.apache.spark.sql.SparkSession = org.apache.spark.sql.SparkSession@17a394d2
```

El punto de entrada a la funcionalidad de la funcionalidad de Spark el comando SparkSession.builder es para crear una session basica.

### Paso 3: colocamos la siguiente linea de codigo

```
val dataSet: Dataset[String] = spark.read.textFile("textfile.csv")
val df: DataFrame = dataSet.toDF()
```

Para poder leer un archivo con extencion ".csv" y lo mostramos.

```
val spark: SparkSession = SparkSession.builder()
    .master("local[*]")
    .appName("simple-app")
    .getOrCreate()

val dataSet: Dataset[String] = spark.read.textFile("textfile.csv")
val df: DataFrame = dataSet.toDF()
```

# Streaming

#### Paso 1: Debemos importar las siguientes librerias

```
import org.apache.spark._
import org.apache.spark.streaming._
import org.apache.spark.streaming.StreamingContext._
```

```
Using Scala version 2.12.15 (OpenJDK 64-Bit Server VM, Java 11.0.17)
Type in expressions to have them evaluated.
Type :help for more information.

Scala> import org.apache.spark._
import org.apache.spark.streaming._
import org.apache.spark.streaming._
import org.apache.spark.streaming._
scala> import org.apache.spark.streaming._
import org.apache.spark.streaming.StreamingContext._
import org.apache.spark.streaming.StreamingContext._
scala> Import org.apache.spark.streaming.StreamingContext._
scala> Import org.apache.spark.streaming.StreamingContext._
```

#### Ahora

## Colocamos la primera linea de codigo

val streamingContext: StreamingContext = new StreamingContext(sparkContext, Seconds(20))

1. Creamos variable StreamingContext, con un tiempo de analisis de datos de 20 segundos

```
scala> val ssc = new StreamingContext(sc, Seconds(20))
ssc: org.apache.spark.streaming.StreamingContext = org.apache.spark.streaming.StreamingContext@18596d47
```

val lines: ReceiverInputDStream[String] = streamingContext.socketTextStream("localhost", 9999)

2. Creamos un DStream que represente la transmission de datos desde una Fuente tcp especificada en el localhost y Puerto 9999

```
scala> val lines = ssc.socketTextStream("localhost", 9999)
lines: org.apache.spark.streaming.dstream.ReceiverInputDStream[String] = org.apache.spark.streaming.dstream.SocketInputDStream@6a8129d1
scala>
```

```
$ nc -lk 9999
hello world
...
```

```
$ ./bin/run-example streaming.NetworkWordCount localhost 9999
...

Time: 1357008430000 ms
(hello,1)
(world,1)
```

val streamingContext: StreamingContext = new StreamingContext(sparkContext, Seconds(20))
val lines: ReceiverInputDStream[String] = streamingContext.socketTextStream("localhost", 9999)

# RDD

```
Using Scala version 2.12.15 (OpenJDK 64-Bit Server VM, Java 11.0.17)
Type in expressions to have them evaluated.
Type :help for more information.

scala> val cadenas = Array("Docentes", "inteligenciaArtificial", "quefinal")
cadenas: Array[String] = Array(Docentes, inteligenciaArtificial, quefinal)

scala> val cadenasRDD = sc.parallelize (cadenas)
cadenasRDD: org.apache.spark.rdd.RDD[String] = ParallelCollectionRDD[0] at parallelize at <console>:24

scala> cadenasRDD.collect()
res0: Array[String] = Array(Docentes, inteligenciaArtificial, quefinal)
```

```
scala> val file = sc.textFile("/home/vmuser/textoRDD", 6)
file: org.apache.spark.rdd.RDD[String] = /home/vmuser/textoRDD MapPartitionsRDD[2] at textFile at <console>:23

scala> file.collect()
org.apache.hadoop.mapred.InvalidInputException: Input path does not exist: file:/home/vmuser/textoRDD
at org.apache.hadoop.mapred.FileInputFormat.singleThreadedListStatus(FileInputFormat.java:304)
at org.apache.hadoop.mapred.FileInputFormat.listStatus(FileInputFormat.java:244)
at org.apache.spark.rdd.HadoopRDD.getPartItions(HadoopRDD.scala:208)
at org.apache.spark.rdd.HadoopRDD.getPartItions(HadoopRDD.scala:208)
at org.apache.spark.rdd.RDD.SanonfunSpartItionsS2(RDD.scala:292)
at scala.Option.getOrElse(Option.scala:189)
at org.apache.spark.rdd.MapPartItionsRDD.getPartItions(MapPartItionsRDD.scala:49)
at org.apache.spark.rdd.RDD.SanonfunSpartItions$2(RDD.scala:292)
at scala.Option.getOrElse(Option.scala:189)
at org.apache.spark.rdd.RDD.SanonfunSpartItions$2(RDD.scala:292)
at org.apache.spark.rdd.RDD.SanonfunSpartItions(RDD.scala:292)
at org.apache.spark.rdd.RDD.SanonfunScollectS1(RDD.scala:293)
at org.apache.spark.rdd.RDD.SanonfunScollectS1(RDD.scala:1021)
at org.apache.spark.rdd.RDD.SanonfunScollectS1(RDD.scala:1021)
at org.apache.spark.rdd.RDD.SanonfunScollectS1(RDD.scala:1021)
at org.apache.spark.rdd.RDD.SanonfunScollectS1(RDD.scala:1021)
at org.apache.spark.rdd.RDD.withScope(RDD.scala:406)
at org.apache.spark.rdd.RDD.withScope(RDD.scala:406)
at org.apache.spark.rdd.RDD.collect(RDD.scala:1020)
... 47 elided
Caused by: java.io.IOException: Input path does not exist: file:/home/vmuser/textoRDD
at org.apache.hadoop.mapred.FileInputFormat.singleThreadedListStatus(FileInputFormat.java:278)
... 63 more
```

```
scala> val filtro = cadenasRDD.filter(line => line.contains("quefinal"))
filtro: org.apache.spark.rdd.RDD[string] = MapPartitionsRDD[3] at filter at <console>:23
scala> val fileNotFound = sc.textFile("/Tanljdlsjd/alkls/", 6)
fileNotFound: org.apache.spark.rdd.RDD[string] = /Tanljdlsjd/alkls/ MapPartitionsRDD[5] at textFile at <console>:23
scala> fileNotFound.collect()
org.apache.hadoop.mapred.fileInputFormat.singleThreadedListStatus(FileInputFormat.java:304)
at org.apache.hadoop.mapred.fileInputFormat.singleThreadedListStatus(FileInputFormat.java:304)
at org.apache.hadoop.mapred.fileInputFormat.getSplits(FileInputFormat.java:332)
at org.apache.spark.rdd.RDD.SanonfunSpartitionsSQ(RDD.scala:208)
at org.apache.spark.rdd.RDD.SanonfunSpartitionsSQ(RDD.scala:208)
at org.apache.spark.rdd.RDD.partitions(RDD.scala:208)
at org.apache.spark.rdd.RDD.partitions(RDD.scala:208)
at org.apache.spark.rdd.RDD.partitions(RDD.scala:208)
at org.apache.spark.rdd.RDD.SanonfunSpartitionsSQ(RDD.scala:209)
at org.apache.spark.rdd.RDD.SanonfunScolectSi(RDD.scala:102)
at org.apache.spark.rdd.RDD.SanonfunScolectSi(RDD.scala:102)
at org.apache.spark.rdd.RDD.SanonfunScolectSi(RDD.scala:102)
at org.apache.spark.rdd.RDD.SanonfunScolectSi(RDD.scala:102)
at org.apache.spark.rdd.RDD.withScope(RDD.scala:406)
at org.apache.spark.rdd.RDD.withScope(RDD.scala:1020)
... 47 elided
Caused by: java.io.IDException: Input path does not exist: file://Tanljdlsjd/alkls
at org.apache.spark.rdd.RDD.sanonfunScolectRDD.scala:1020)
... 63 more
scala>
```

```
val cadenas = Array("Docentes", "inteligenciaArtificial", "quefinal")
val cadenasRDD = sc . parallelize (cadenas)
cadenasRDD.collect()
file.collect()
val filtro = cadenasRDD.filter(line => line.contains("quefinal"))
val fileNotFound = sc.textFile("/7añljdlsjd/alkls/", 6)
fileNotFound.collect()
```

En github tienen que subir en un repositorio los códigos de cada pregunta(carpeta), darle mínimamente acceso a <a href="mailva@fcpn.edu.bo">msilva@fcpn.edu.bo</a>, mandar al correo con referencia "20 parcial 319", notificar al mismo correo hasta el día 12 de diciembre a horas 12:00.